

REPORT

Azərbaycan dili üçün Avtomatik Nitq Tanıma (ASR) sisteminin
qurulması

İbrahim Abbasov

Hissə C — Analitik Hesabat

C1. Çətinliklər və Həllər

Hansı texniki problemlərlə üzləşdiniz və onları necə həll etdiniz?

Əsas problemlər Hugging Face datasets kitabxanasındakı versiya xətalrı, GPU yaddaş çatışmazlığı (OOM) və dataset seçimi olmuşdur. Kitabxana stabil versiyaya (datasets<3.0.0) endirildi. Tapşırıqda tövsiyə olunan *Mozilla Common Voice* datasetini yükləmək üçün xüsusi istifadəçi razılığı və HF_TOKEN tələb olduğundan, kodu yoxlayan şəxs üçün prosesi çətinləşdirməmək (tam "out-of-the-box" işləməsi) məqsədilə, açıq mənbəli və eyni dərəcədə keyfiyyətli olan google/fleurs dataset-inə şüurlu şəkildə keçid edildi. GPU yaddaş problemi isə gradient_accumulation_steps=2 və 16-bit hesablamalar (fp16=True) ilə həll olundu.

Azərbaycan dilinin xüsusiyyətləri ASR-ı necə çətinləşdirir?

Dilin aqlütinativ olması (çoxlu şəkilçi qəbulu) söz formalarını sonsuzlaşdırır və OOV (Out-of-Vocabulary) problemini artırır. Xüsusi hərflərin (ə, ö, ğ, ı, ş, ç) mövcudluğu isə modelin lüğət (vocabulary) bazasını mürəkkəbləşdirir.

C2. Nəticələrin Təhlili

Model / Step	Training Loss	Validation Loss	WER (%)	CER (%)
Baza Modeli	-	-	119.94%	78.55%
Step 25	5.499614	2.602171	161.46%	~105.55%
Step 50	3.578035	2.296861	178.50%	~105.55%
Fine-Tuned (Yekun Test)	-	-	117.09%	74.01%

Table 1: Fine-Tuning təlim gedişatı və test nəticələri



Figure 1: Təlim prosesində Loss və WER




Figure 2: Baza və Fine-Tuned müqayisəsi

Overfitting-in qarşısının alınması və Validation WER

Təlim prosesi bilərəkdən çox qısa — cəmi 50 addımla məhdudlaşdırılmışdır (early stopping analoqu). Bu strateji qərar modelin kiçik dataseti (150 nümunə) əzbərləməsinin (**overfitting**) qarşısını almışdır.

Təlim zamanı Validation WER-in yüksələrək baza modeldən (119.94%) daha yuxarı (178.50%) olması modelin həddindən artıq öyrənməsi deyil, əksinə hələ **underfitting** (başlangıç) mərhələsində olduğunu və qradientlərin hələ tam stabilləşmədiyini göstərir.

Yekun Test setində WER-in **117.09%-ə** və CER-in **74.01%-ə** düşməsi (baza modelə nisbətən kiçik yaxşılaşma) təlimin doğru istiqamətdə getdiyini göstərir, lakin daha yüksək nəticə üçün daha çox məlumat və təlim addımına ehtiyac var. Qiymətləndirmə zamanı `forced_decoder_ids` parametrindən istifadə edilmişdir.

Model hansı növ səhvlər edir?

- **Akustik:** Kontekst itdikdə eyni hecanın sonsuz təkrarı (hallüsinasiyalar).
- **Leksik:** Dili tanımayaraq fərqli simvollar və ya yad dillərdə qarşılıqlar verməsi.
- **Fonetik:** Spektroqramları bənzər olan səslərin (məs: q/ğ, k/g) dəyişik salınması.

Hansı audio şəraitlərində model daha yaxşı / daha pis işləyir?

Model təmiz və fasiləsiz diksiyalı audiolarda uğurludur. Uzun sükut və ya arxa fon səs-küyü isə modelin *Attention* mexanizmini pozaraq hallüsinasiyalara səbəb olur.

C3. Yaxşılaşdırma Yolları

Bu pipeline-ı production-a aparmaq üçün nə etmək lazımdır?

Daha böyük baza modeli (Whisper-medium), minlərlə saatlıq təmiz data və multi-GPU infrastrukturunda tam miqyaslı təlim tələb olunur.

Daha çox resurs olsaydı, növbəti 3 addım nə olardı?

1. **Data Augmentation:** Audiolara süni küy əlavə edərək dataseti genişləndirmək.
2. **Hyperparameter Tuning:** Optimal `learning_rate` və `batch_size` axtarışı.
3. **Optimizasiya:** İcra sürəti üçün modeli ONNX və ya TensorRT formatına çevirmək.

Azərbaycan dili üçün ASR-ın ən böyük problemi: Yüksək keyfiyyətli və açıq mənbəli audio-transkripsiya məlumat bazalarının kəskin çatışmazlığı.